2026-10-29 · 夜里复盘

从「能答」到「答得对」，今晚卡在哪

RAG 第五站上线，然后三次实验里被打脸两次。
这篇只留结论，不写过程。

4/4
跑通的问题
3 对 1 错

2
被数据推翻的
假设

3
同一个指标下的
三种病

一、answer.py 的三道闸门

检索、阈值、prompt，三件事管三件事，不能互相顶替。

```
def answer(question, key=None, dry=False):
    hits = search(question, k=TOP_K)      # ① 检索：找不到就全完
    top = hits[0][1]

    if top < MIN_SCORE:                   # ② 阈值 0.60：不够像就拒答，省一次调用
        return {..., "answer": None, "refused": True}

    prompt = build_prompt(question, hits)
    text, usage = ask_llm(prompt, key)    # ③ prompt 四条铁律：只准用材料、每句标 [n]
    return {...}
```

三道闸门分工明确，实测各管一段：

题目	top1 分	结果	哪道闸门起作用
USB-C 接外部工具	0.985	答对，标 [1]	① 检索
CrewAI 和 AutoGen 怎么选	0.969	「材料里没有」	③ prompt 兜住 T3
北京好吃的火锅店	0.156	阈值拒答	② 阈值挡 T1
什么是智能体?	0.999	「材料里没有定义」	① 检索喂错料

> **最值钱的一条**
>
> **最后那题，模型没说错，材料里真的没有定义。**它读到的是 191 字的结尾段，讲神经符号主义。
>
> 生成端的诚实，不能证明检索端正确。**拒答机制生效了——但它拒掉了一道本该答对的题，这叫假阴性。**

二、那道题为什么错

1.1 节被切成 **12 块，12 块标题完全一样**（`## 1.1 什么是智能体？`）。我把标题拼进了正文去向量化和精排，于是 cross-encoder 看到问题和标题字面雷同，12 块分数全挤成一团：

```
idx  len   带标题   不带标题
  1  663   0.998    0.996   << 真定义（是的，结尾段比它低）
 12  191   0.999    0.992   << 实际被选中的那块
 10  698   0.991    0.061
 11  750   0.974    0.020
```

带标题时最高分和最低分只差 **0.025**，区分度归零。去掉标题立刻拉到 0.996 vs 0.020。

看起来答案很明确了：别拼标题。然后我跑了全量。

三、两次被数据打脸

第一次：以为标题污染精排

配置	@1	@3	对比基线
基线（带标题 PER=2）	0.651	0.907	—
B 去标题 PER=2	0.605	0.860	−5.0 / −4.7 点
C 去标题 PER=3	0.605	0.884	−4.6 / −2.3 点

两个方案都低于基线。原因很简单：43 题里有 41 题，标题本身就是答案。问「用状态图编排智能体流程的框架是哪个」，标题就是 `## 6.5 框架四：LangGraph`，去掉等于自断一臂。

1.1 那 12 块**是特例**——它们标题相同，才会饱和。别的节标题各不相同，饱和不会发生。

第二次：以为按 `###` 切能救

1.1 节本来有 3 个三级标题（`1.1.1 传统视角` / `1.1.2 大模型新范式` / `1.1.3 智能体的类型`），但切块只认 `##`，这些边界全丢了。

改了 `chunk_by_heading` 支持 `level=3`，块数 1177 → 1305。1.1 节从 **12 块变成 13 块**——只是多贴了标签，**碎还是那么碎。**三题验证：**1/3 → 1/3，零改善。**

根因：语料里 293 个三级子节，**86% 超过 800 字。**切完照样被 `split_long` 打碎。而 800 这个上限动不了——`bge-small-zh` 只吃 512 token ≈ 880 字，再大尾巴就被截断。

> **两次栽在同一个坑**
>
> 第一次改「标题怎么拼」，第二次改「按几级标题切」——**都在改块，可问题根本不在块上。**
>
> 单题诊断只能**提出假设**，全量评估才能**验证假设**。顺序反了，就白干两轮。

四、真病根：票太少

把失败题的块数拉出来，一眼就看到问题了：

```
# 节内块数 —— 就是被切碎的程度
## 1.1   12 块
## 8.3   22 块   ← 检索失败
## 4.2   24 块   ← 检索失败

N_SECTIONS    = 15   # 粗筛取 15 个节
PER_SECTION   = 2    # 每节只发 2 张入场券 ⟵ 病根
```

一个 24 块的节，只给 2 张票。粗筛先筛掉 22 块，剩下的 2 块送去精排，真答案压根没上桌。

1.1 那题之所以选出尾巴块，不是精排眼瞎，是**真定义在粗筛那关就被挤掉了**。我在精排上折腾了半天，病灶在上一站。

合理的改法是按节的大小发票：

```
per = max(2, min(8, 块数 // 3))   # 12块→4票，24块→8票，小节能2票
```

但精排对数会从 30 涨到 70，单题 11.4s → 20s。**线上不可能接受**，所以这条得和性能优化一起做，不能单干。

五、一个 @3 底下，藏着三种病

今晚最重要的一页。同一个 `@3 = 0.907`，三种完全不同的病因，药方互不相通：

病症	长什么样	该动哪里
找对了块，挑错了	1.1 尾块 0.999，真定义 0.998	配额 / 块粒度
大节进不来	8.3 有 22 块，只进 2 块	配额策略
根本没找对章节	8.3 / 4.2 分数只有 0.79	**查询改写 / HyDE**

第三种是真正的天花板。看这两道题：

用户怎么问	书里怎么写	top1 分
先检索外部资料再让模型生成答案，这套做法叫什么？	## 8.3 检索增强生成（RAG）	0.790 → 3.3 缩放法则
一边推理一边调用工具的范式是怎么运作的？	## 4.2 ReAct（Reason + Act）	0.854 → 4.3 Plan-and-Solve

问题里**一个术语都没出现**，而文档全靠术语。bi-encoder 建立不了「先检索再生成 ↔ RAG」这个映射——**这套系统骨子里还是关键词检索，问题换个说法就失效**。

六、睡前记住这五句

- **生成端诚实 ≠ 检索端正确。**模型说「材料里没有」，可能是你根本没喂给它。
- **指标不告诉你病因。**@3 掉了两个点，可能是三种病里的任何一种，只能逐个看失败题。
- **单题只能提假设，全量才能验证。**今晚两次打脸，都是拿一道题的现象去改全局。
- **改之前先判断病灶在哪一站。**我在精排上折腾两轮，病在粗筛的配额。
- **术语鸿沟是天花板。**向量检索再调，也补不上「口语问法」和「术语标题」之间的裂缝。

> **明天的第一步**
>
> 查询改写：让模型先把「先检索外部资料再生成」改写成「检索增强生成 RAG」，再去检索。
>
> 如果有效，再上 HyDE（先让模型编一个假答案，拿假答案去检索）。**今天不猜参数了，先给失败题分类再动手。**

今天的代码：`answer.py`（生成站）、`exp_title.py` / `exp_h3.py`（两个反面教材）。
数据日志：`exp_title.log`、`exp_h3.py` 输出、`abstain.log`。